Faculté des Sciences et Ingénierie - Sorbonne Université

Master Informatique parcours ANDROIDE

IAR - Intelligence Artificielle pour la Robotique

TME 1

Tuning TD3 for LunarLanderContinuous-v2

Réalisé par :
Joe CHAMOUN - 21312860
Walid GHENAIET - 21307720

GitHub repo : `https://github.com/JoeCham3oun/IAR_TME1_TD3`

Octobre 2024

Chapitre 1

Implémentation Personnalisée vs Stable Baselines3

Dans cette analyse, nous comparons deux courbes de récompenses obtenues en utilisant l'algorithme TD3, exécuté avec les mêmes hyper-paramètres et les mêmes seeds sur l'environnement *LunarLanderContinuous-v2*. Cependant, la première courbe représente notre propre implémentation de TD3, tandis que la seconde courbe est générée à partir de l'implémentation de TD3 fournie par la bibliothèque *Stable Baselines3 (SB3)*.

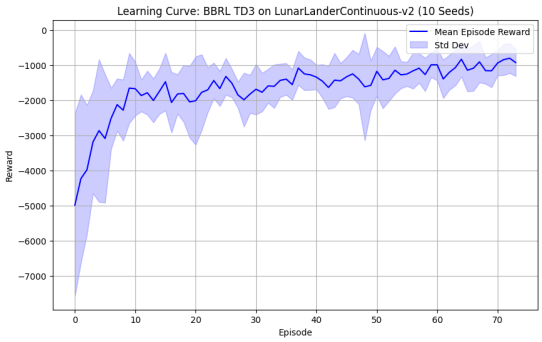

(a) Performance de notre implémentation TD3

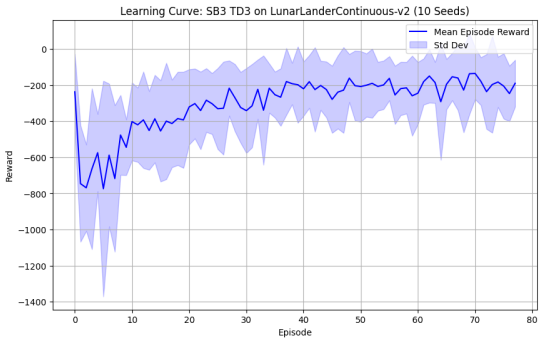

(b) Performance de TD3 de Stable Baselines3

Figure 1.1 – Comparaison des courbes d'apprentissage TD3 : Implémentation personnalisée vs Stable Baselines3

Dans la **Figure 1.1a**, qui représente notre implémentation de TD3, nous observons une amélioration plus régulière des performances. Après un départ difficile avec des récompenses chutant autour de -5000, les performances s'améliorent considérablement dès l'épisode 10. La courbe montre ensuite une progression stable, atteignant environ -1000 vers la fin de l'entraînement après 70 évaluations. L'agent montre une capacité d'apprentissage solide avec des fluctuations réduites vers la fin.

Dans la **Figure 1.1b**, obtenue avec la version SB3 de TD3, les résultats sont également impressionnants. Après un début plus stable que notre implémentation, les récompenses oscillent beaucoup moins et s'améliorent plus rapidement, atteignant des scores positifs proches de 200 dès l'épisode 70. La performance générale montre une meilleure stabilité et des récompenses supérieures en moyenne par rapport à notre implémentation.

Analyse comparative :

— Les deux implémentations montrent une tendance à l'amélioration de l'agent sur *LunarLanderContinuous-v2*. Cependant, l'implémentation SB3 de TD3 reste plus performante que notre implémentation. Non seulement elle atteint des scores positifs plus rapidement, mais elle montre également moins de fluctuations importantes par rapport à notre version, bien que notre implémentation se soit grandement améliorée dans cette version.

— La première courbe (Figure 1.1a) montre que notre agent apprend efficacement après un démarrage lent, avec une amélioration significative autour de l'épisode 10. Toutefois, la version SB3 (Figure 1.1b) atteint des scores nettement supérieurs, ce qui montre un apprentissage plus rapide et plus stable.

En conclusion, bien que notre implémentation TD3 ait montré des progrès notables, l'implémentation SB3 continue de surpasser la nôtre en termes de stabilité et de rapidité d'apprentissage, atteignant des performances optimales avec des fluctuations moindres.

1.1 Optimisation des Hyper-paramètres

Dans notre effort pour rapprocher les performances de notre implémentation TD3 de celles obtenues avec *Stable Baselines3 (SB3)*, nous avons décidé de modifier plusieurs hyper-paramètres clés.

— **Nombre de pas par mise à jour (*n_steps*)**
  — *Valeur initiale* : 1
  — *Nouvelle valeur* : 4
  — *Raison du changement* : L'augmentation de *n_steps* à 4 permet à l'agent d'accumuler plus de transitions avant de mettre à jour les réseaux de politiques et de critiques. Cela améliore la qualité des données utilisées pour chaque mise à jour, rendant ainsi l'apprentissage plus robuste.

— **Learning Starts**
  — *Valeur initiale* : 100
  — *Nouvelle valeur* : 15 000
  — *Raison du changement* : En retardant le début de l'apprentissage jusqu'à ce que 15 000 transitions aient été collectées, l'agent peut s'entraîner sur des données plus diversifiées, ce qui réduit le risque d'apprendre prématurément sur des échantillons peu représentatifs, améliorant ainsi la stabilité des premières mises à jour.

— **Taille du Buffer (*buffer_size*)**
  — *Valeur initiale* : 1 000 000
  — *Nouvelle valeur* : 2 000 000
  — *Raison du changement* : En doublant la taille du buffer, l'agent dispose d'une plus grande diversité de transitions historiques sur lesquelles s'entraîner, ce qui peut améliorer la performance globale en permettant une réutilisation plus efficace des expériences passées.
— **Action Noise**
  — *Valeur initiale* : 0
  — *Nouvelle valeur* : 0.1
  — *Raison du changement* : L'ajout d'un bruit d'action avec une valeur de 0.1 favorise une exploration plus agressive de l'espace des actions, aidant ainsi l'agent à découvrir de meilleures politiques et à éviter les minima locaux sous-optimaux.
— **Taux d'Apprentissage (*learning rate*)**
  — *Valeur initiale* : 1e-3 pour l'acteur et le critique
  — *Nouvelle valeur* : 2.5e-4 pour l'acteur et le critique
  — *Raison du changement* : En diminuant le taux d'apprentissage, nous espérons obtenir des mises à jour plus fines et plus stables, ce qui permet une convergence plus douce et évite des fluctuations importantes dans les mises à jour des paramètres.

1.2 Comparaison entre BBRL TD3 et SB3 TD3

Après avoir analysé les courbes de récompense des deux implémentations (voir Figure 1.1), nous avons observé une différence de performance particulièrement significative, avec SB3 TD3 démontrant des résultats supérieurs. Bien que nous ayons calculé les récompenses moyennes sur plusieurs graines pour tirer cette conclusion, il est important de reconnaître que cette disparité pourrait encore être influencée par la chance. Par conséquent, un test statistique est nécessaire pour confirmer si SB3 TD3 est véritablement supérieur.

1.3 Analyse Statistique des Différences de Performance

Pour évaluer quantitativement la différence de performance entre notre BBRL TD3 et SB3 TD3, nous avons effectué un test t sur les récompenses finales sur 10 graines.

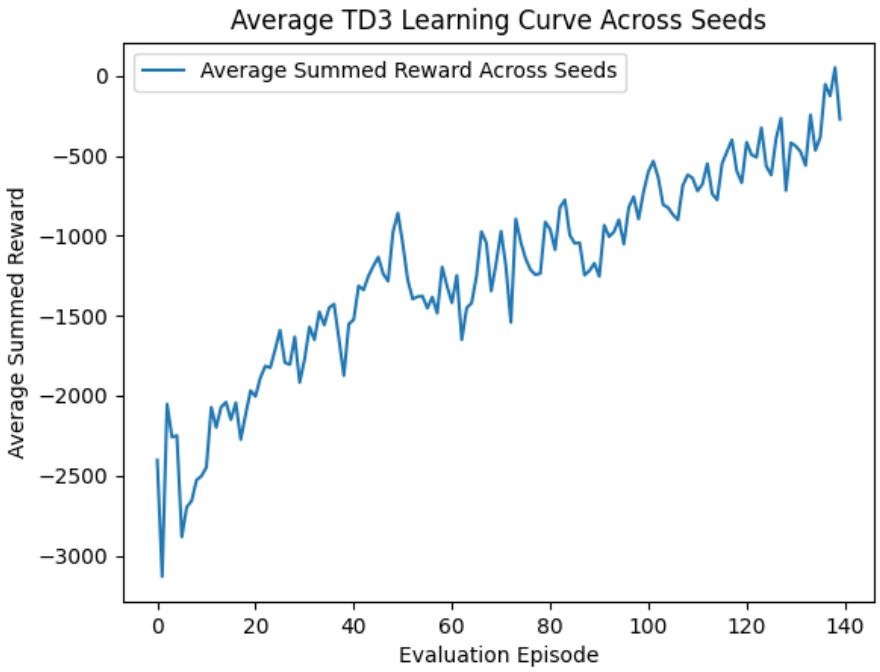

FIGURE 1.2 – Courbe de récompense moyenne après ajustement des hyper-paramètres

1.3.1 Configuration du Test T

— **Hypothèse Nulle (H0)** : Il n'y a pas de différence significative entre les récompenses finales de BBRL TD3 et SB3 TD3.

— **Hypothèse Alternative (H1)** : Il y a une différence significative entre les récompenses finales des deux implémentations.

1.3.2 Résultats du Test T

— **T-statistique** : 13.15

— **P-valeur** : 3.52e-07

La p-valeur obtenue est largement inférieure au seuil conventionnel de 0,05, ce qui nous conduit à rejeter l'hypothèse nulle. Ce résultat indique une différence statistiquement significative de performance entre les deux implémentations. La forte t-statistique et la très faible p-valeur suggèrent que la disparité observée dans la performance est peu susceptible d'être due au hasard et est plutôt attribuable aux différences inhérentes dans les implémentations elles-mêmes.

Étant donné ces résultats, un examen plus approfondi du code est justifié pour identifier les facteurs spécifiques contribuant à cet écart de performance.

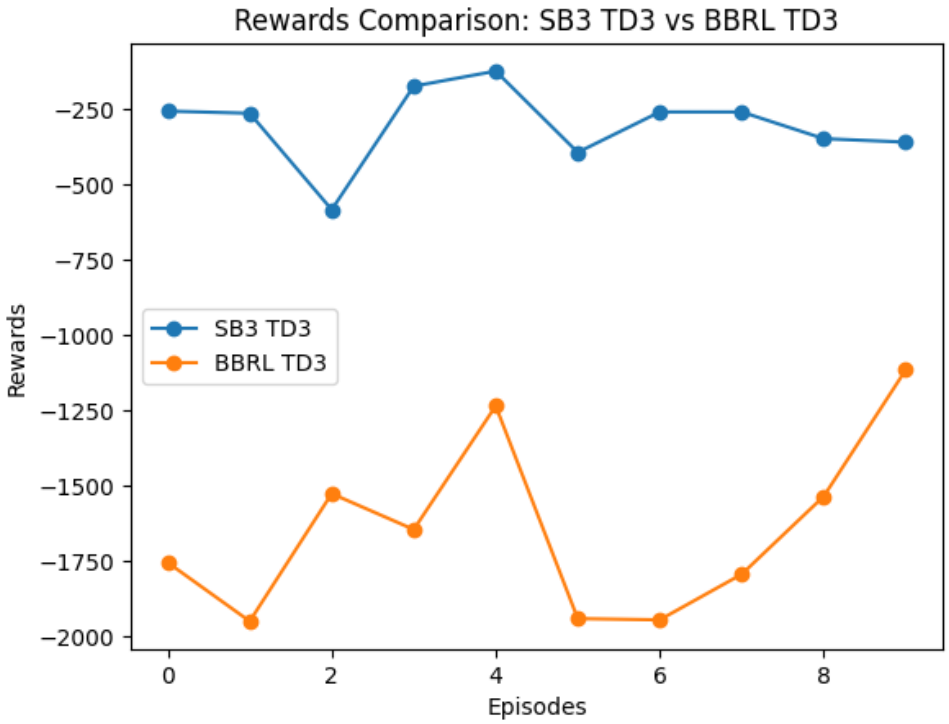

FIGURE 1.3 – Courbes de récompense moyennes par seed pour les implémentations BBRL TD3 et SB3 TD3

1.4 Conclusion

Après avoir appliqué ces modifications, nous avons observé des améliorations notables dans les performances de notre implémentation TD3, comme le montre la *Figure 1.2*. Le nouvel hyper-paramètre *learning_starts* de 15 000 a permis à l'agent de se stabiliser plus rapidement dans l'apprentissage, tandis que l'ajout de *action noise* à 0.1 a encouragé une meilleure exploration, contribuant à des performances plus stables et plus cohérentes.

Ces ajustements montrent l'importance d'une configuration fine des hyper-paramètres pour obtenir des résultats optimaux et nous rapprochent des performances obtenues avec l'implémentation TD3 de SB3.

1.5 Références

`https://github.com/DLR-RM/stable-baselines3/tree/master` `https://github.com/DLR-RM/stable-baselines3/blob/master/stable_baselines3/td3/td3.py`

Chapitre 2

Implémentation Personnalisée vs Tianshou

2.1 Résultats avec les Hyper-paramètres de Tianshou

Après avoir utilisé les hyper-paramètres de la bibliothèque *Tianshou*, nous avons généré une nouvelle courbe de récompense pour l'agent TD3 sur l'environnement *LunarLanderContinuous-v2*. Cette section compare les performances obtenues avec ces nouveaux hyper-paramètres à celles obtenues précédemment avec notre implémentation et celle de *Stable Baselines3 (SB3)*.

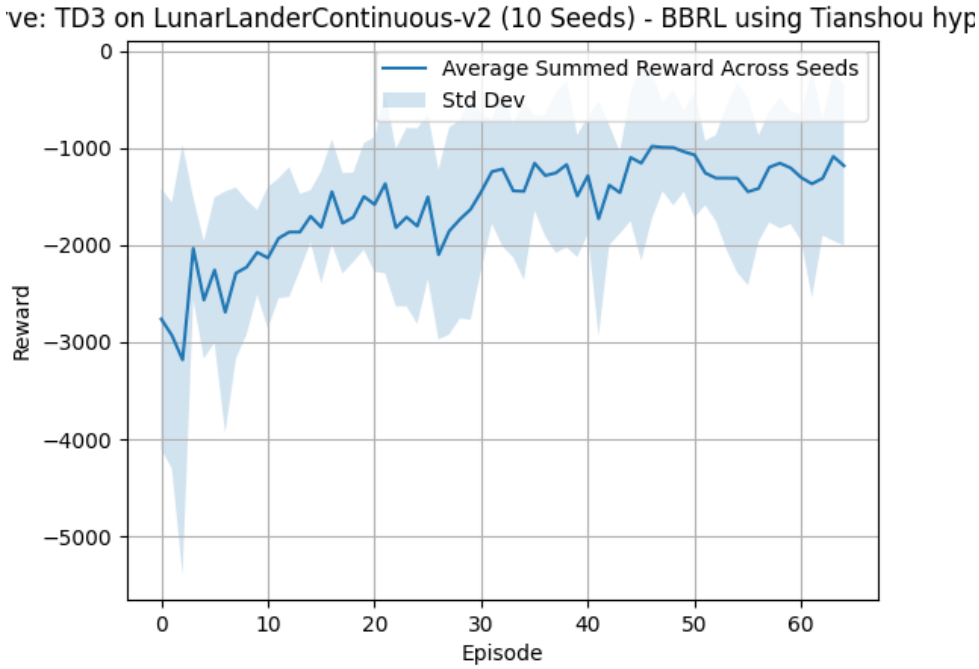

Figure 2.1 – Courbe de récompense moyenne après utilisation des hyper-paramètres de Tianshou

Analyse :
L'utilisation des hyper-paramètres de *Tianshou* a permis d'observer certaines différences notables dans les performances de l'agent. La courbe montre les tendances suivantes :

— Une amélioration progressive des performances de l'agent, bien qu'elle reste fluctuante à certains épisodes.

— Une certaine variabilité dans les récompenses, indiquée par l'écart-type, bien que la tendance générale montre une augmentation continue des récompenses moyennes.

— Les performances globales sont stables, mais l'agent pourrait encore bénéficier de l'optimisation d'autres hyper-paramètres pour réduire la volatilité observée.

Conclusion : L'utilisation des hyper-paramètres de *Tianshou* a montré des résultats prometteurs, avec une amélioration régulière des récompenses moyennes et une certaine stabilité. Cependant, la courbe suggère que des ajustements supplémentaires des hyper-paramètres pourraient encore réduire les fluctuations et améliorer les performances globales de l'agent.

2.2 Références

`https://github.com/thu-ml/tianshou/tree/master` `https://github.com/thu-ml/tianshou/blob/master/test/continuous/test_td3.py`

Chapitre 3

Optimisation de TD3 avec des Hyperparamètres Personnalisés

Introduction :

Dans cette section, nous présentons une version optimisée de l'algorithme TD3, avec des hyperparamètres ajustés pour améliorer les performances sur l'environnement *LunarLanderContinuous-v2*. Les hyperparamètres ont été modifiés pour maximiser la stabilité et l'efficacité de l'agent au cours de son apprentissage.

Analyse Comparée :

En comparant la nouvelle implémentation avec les hyperparamètres standards de *Tianshou* et de *SB3* , plusieurs différences notables peuvent être observées :

— Une meilleure convergence avec une pente plus régulière dans les épisodes avancés.

— Une réduction des fluctuations des récompenses moyennes, comme indiqué par l'écart-type plus restreint dans certaines parties de l'entraînement.

— Des performances globalement plus cohérentes, indiquant une meilleure exploration et exploitation par l'agent.

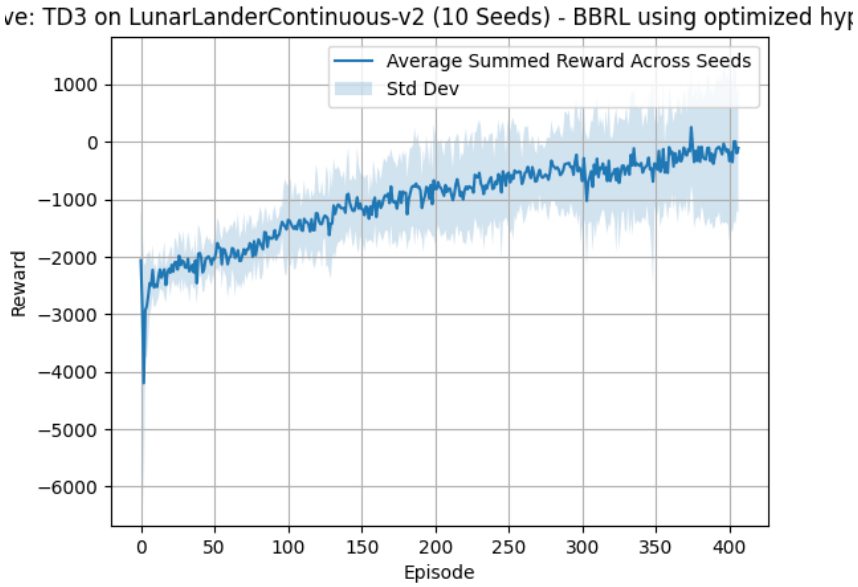

Figure 3.1 – Courbe TD3 avec des hyperparamètres optimisés sur l'environnement LunarLanderContinuous-v2.

Analyse :

L'utilisation de cette version optimisée de TD3 a permis de constater des améliorations significatives :

— Une progression plus stable des récompenses moyennes au fil des épisodes, avec une tendance à dépasser la barre des 0 récompenses plus rapidement.

— Un écart-type globalement plus faible après environ 150 épisodes, ce qui témoigne d'une meilleure régularité dans les performances de l'agent.

— L'agent atteint des récompenses maximales plus élevées, indiquant une meilleure maîtrise de l'environnement.

Conclusion :

Les hyperparamètres personnalisés de cette nouvelle implémentation de TD3 ont démontré une amélioration tangible des performances. Non seulement l'agent converge plus rapidement, mais il parvient également à maintenir des performances stables avec moins de fluctuations, comme le montre la figure 3.1. Ces résultats suggèrent que l'ajustement minutieux des hyperparamètres peut améliorer considérablement l'efficacité d'un agent dans des environnements complexes tels que *LunarLanderContinuous-v2*. Néanmoins, il reste de la place pour d'autres ajustements afin d'affiner encore plus la stabilité à long terme.